Tensorflow2.0 Tutorial

Jingjing Gong

什么是TensorFlow?

- Google brain开发用来做机器学习以及深度学习研究的工具
- 多平台支持，服务器，个人电脑，移动设备
- 支持多卡，分布式计算
- 灵活，具有通用性，可以用在其它领域
- 当前支持python, java以及c++接口
- **可以自动求导**
- **可以方便的利用GPU**

还有哪些主流深度学习框架?

- Pytorch (Dynamic Graph)　　[facebook]
- PaddlePaddle (Static Graph)　[百度]
- MxNet (Static Graph).　　[amazon]
- caffe, Theano, etc.　（过时的历史框架）

按照执行方式分类

动态图

- **Tensorflow** (**Eager Mode**)
- Pytorch

静态图

- **Tensorflow** (Graph Mode)
- MxNet
- caffe
- Theano
- PaddlePaddle

Dynamic Graph vs. Static Graph

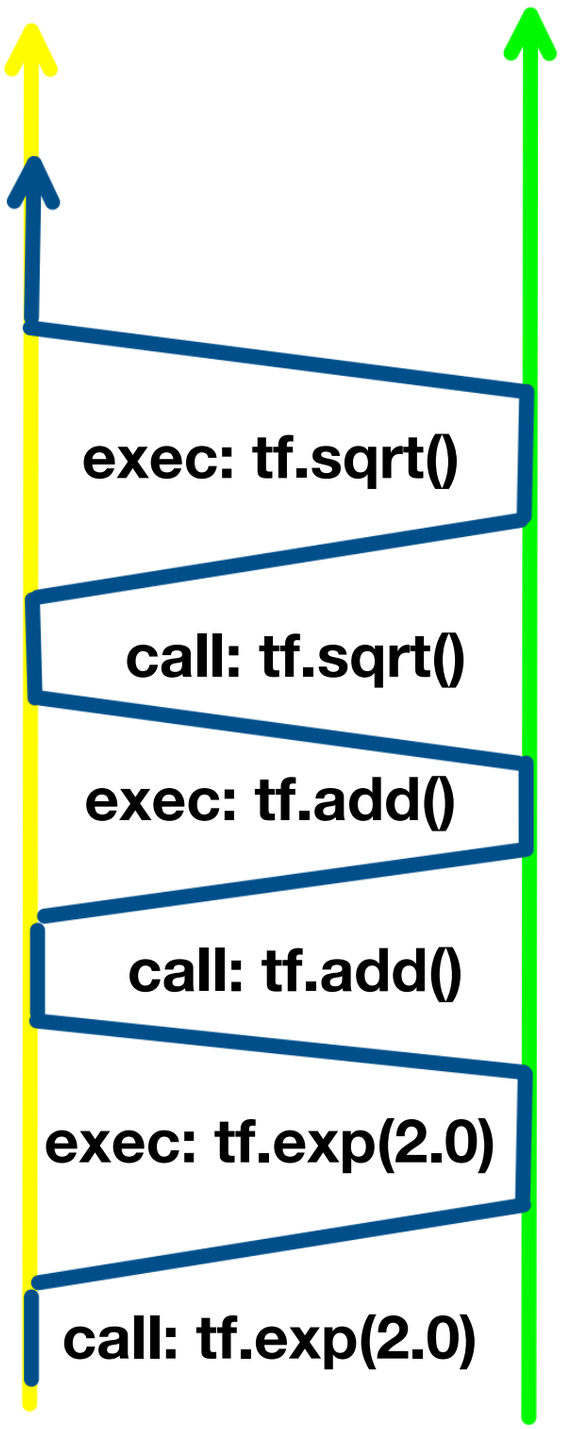

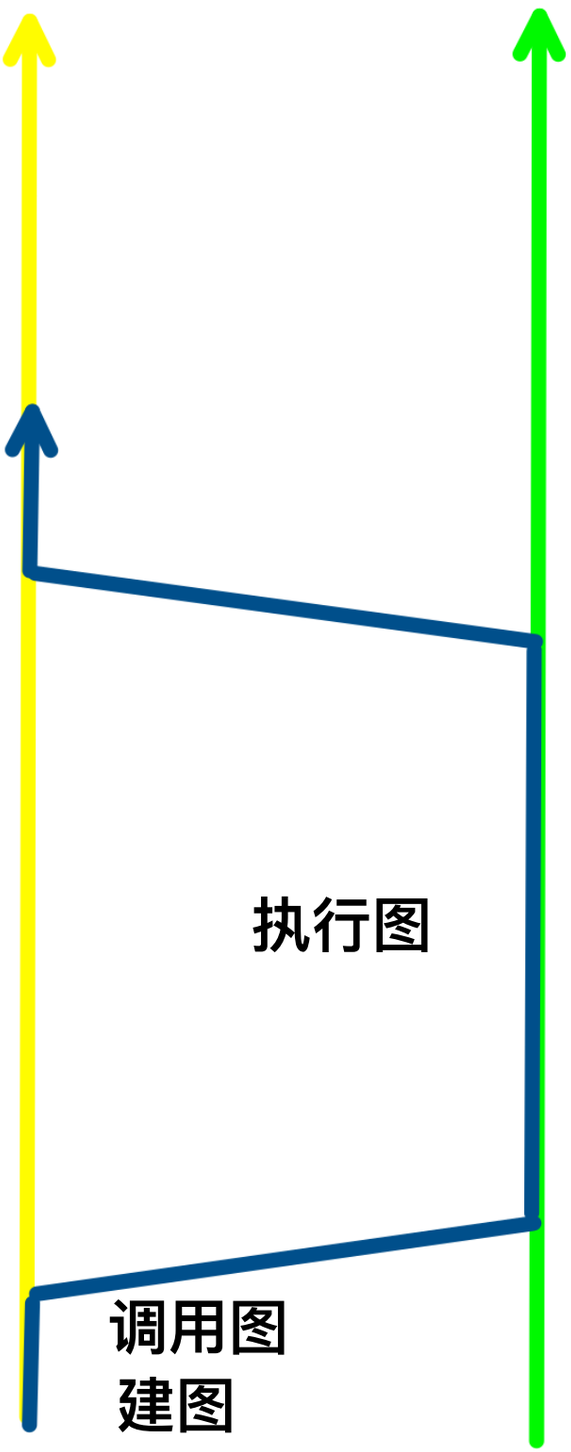

Python Routine

TF Sub-routine

```
aa = tf.exp(2.0)
bb = tf.add(aa, 1.)
cc = tf.sqrt(bb)
```

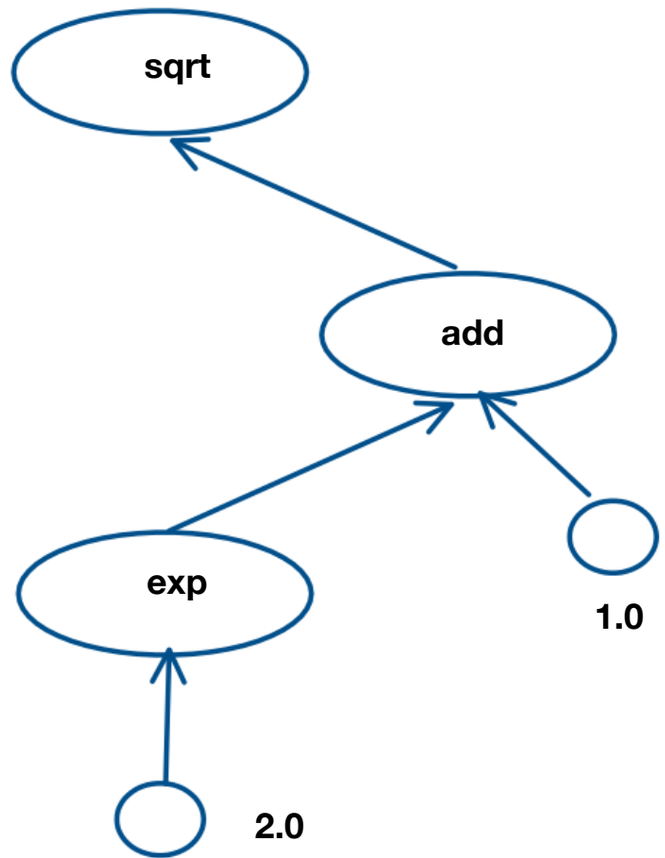

为什么需要这些框架?

这得从学习问题本身说起

学习问题（不严谨）

对于一些观测样本$\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \ldots, (\mathbf{x}_n, y_n)\}$,其中$y$是对应输入$\mathbf{x}$的标签。

我们定义一个函数 $y = f(\mathbf{x}, \mathbf{w})$，其中$f(\cdot, \mathbf{w})$是一个函数家族，我们也把它叫做**模型**，$\mathbf{w}$是这个模型的参数 。

学习目标就是找到一个$\mathbf{w}^*$ 使得观测样本尽可能满足$y = f(\mathbf{x}, \mathbf{w}^*)$这个等式（经验风险最小化），我们把它称作**优化**过程

怎么优化？梯度下降

我们可以定义一个连续平滑的函数$\mathcal{L}$用来描述模型预测$f(\mathbf{x}, \mathbf{w})$跟实际标签$y$的距离：

$$\mathcal{L}(y, f(\mathbf{x}, \mathbf{w}))$$

对于所有样本这个误差可以描述为：

$$\mathbf{L}(\mathbf{w}) = \frac{1}{n}\sum_{i=1}^{n}\mathcal{L}(y_i, f(\mathbf{x}_i, \mathbf{w}))$$

我们可以使用梯度下降找到$\mathbf{w}^*$，但这要求我们求到：$\frac{\partial \mathbf{L}}{\partial \mathbf{w}}$,这样我们可以迭代优化$\mathbf{w}$：

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \gamma\frac{\partial \mathbf{L}}{\partial \mathbf{w}_t}$$

怎么求$\frac{\partial \mathbf{L}}{\partial \mathbf{w}}$？链式求导

$$\frac{\partial \mathbf{L}}{\partial \mathbf{w}} = \frac{1}{n}\sum_{i=1}^{n}\frac{\partial \mathcal{L}(y_i, f(\mathbf{x}_i, \mathbf{w}))}{\partial \mathbf{w}}$$

从前，对于**每一个模型**我们都需要用通过链式法则用笔求出梯度公式：

$$\frac{\partial \mathcal{L}(y_i, f(\mathbf{x}_i, \mathbf{w}))}{\partial \mathbf{w}}$$

然后写大量代码通过给$\mathbf{w}$加扰动计算数值的梯度跟上面公式求出的梯度进行对比。这个过程会耗费大量精力，然而链式求导却是一个非常机械的过程。

在Tensorflow中，求梯度非常简单

```
#take gradient of a variable
def func(w):                                    定义的目标函数，可以任意复杂
    aa = tf.exp(w)
    bb = tf.add(aa, 1.)
    cc = tf.sqrt(bb)
    return cc

w = tf.Variable(2.0, dtype=tf.float32)      参数
with tf.GradientTape() as tape:
    y = func(w)
print(tape.gradient(y, w))                          求导数
```

```
tf.Tensor(1.2755646, shape=(), dtype=float32)
```

Easy like a pie :)

Tensorflow的一些基础操作

- tf.Variable()
- tf.constant()
- tf.zeros
- tf.ones
- tf.zeros_like
- tf.ones_like
- tf.random

- tf.add, tf.subtract
- tf.multiply, tf.divide
- tf.exp, tf.sqrt
- tf.sin, tf.cos
- 基本的数学运算都有

tf.Variable

- tf.Variable叫做变量对象，可以对应之前讲的参数w。在人工神经网络中，通常用来存储连接的权重。对于所有样本可访问的全局量。
- 在Tensorflow中只有Variable 可以被赋值：

```
aa = tf.Variable(2.0)
print(aa)
aa.assign(3.0)
print(aa)
aa.assign_add(2.0)
print(aa)
aa.assign_sub(1.0)
print(aa)
```

```
<tf.Variable 'Variable:0' shape=() dtype=float32, numpy=2.0>
<tf.Variable 'Variable:0' shape=() dtype=float32, numpy=3.0>
<tf.Variable 'Variable:0' shape=() dtype=float32, numpy=5.0>
<tf.Variable 'Variable:0' shape=() dtype=float32, numpy=4.0>
```

tf.GradientTape

- 在这个context下的操作如果它的至少一个输入被watch了，那么这个操作也会被记录（中间结果会被记住）
- 对于变量（tf.Variable），会被自动记录。
- 配合demo_code:Gradient Tape watch 演示

```
x = tf.ones((2, 2))

with tf.GradientTape() as t:
  t.watch(x)
  y = tf.reduce_sum(x)
  z = tf.multiply(y, y)

# Derivative of z with respect to the original input tensor x
dz_dx = t.gradient(z, x)
```

tf.GradientTape

- 取了一次gradient之后记录的中间结果就会被销毁，如果需要取多次graidnet，那么把persistent设置成True。

```
x = tf.constant(3.0)
with tf.GradientTape(persistent=True) as g:
  g.watch(x)
  y = x * x
  z = y * y
dz_dx = g.gradient(z, x)  # 108.0 (4*x^3 at x = 3)
dy_dx = g.gradient(y, x)  # 6.0
```

为什么要记住中间结果?

tf.function

- 对于一个函数使用tf.function 修饰符，相当于把整个函数中的很多operation打包成一个operation。

- 在函数中尽量使用原生tensorflow 的操作，尽管对于某一些python操作也会解析成Graph的一部分。

```
@tf.function
def func(inp):
    aa = tf.exp(inp)
    bb = tf.add(aa, 1.)
    cc = tf.sqrt(bb)
    return cc
```

为什么要用tf.function修饰?

- 对于没有使用tf.function的tensorflow计算函数，函数内部执行是在Eager Mode下完成的，每一个内部操作都需要做上下文切换。

- 而使用了tf.function修饰的函数被编译成一个完整的操作，内部操作是在Graph Mode下完成的，整个函数可以看作是一个操作，这样效率会相对比较高。

为什么要用tf.function修饰?

记住这张PPT

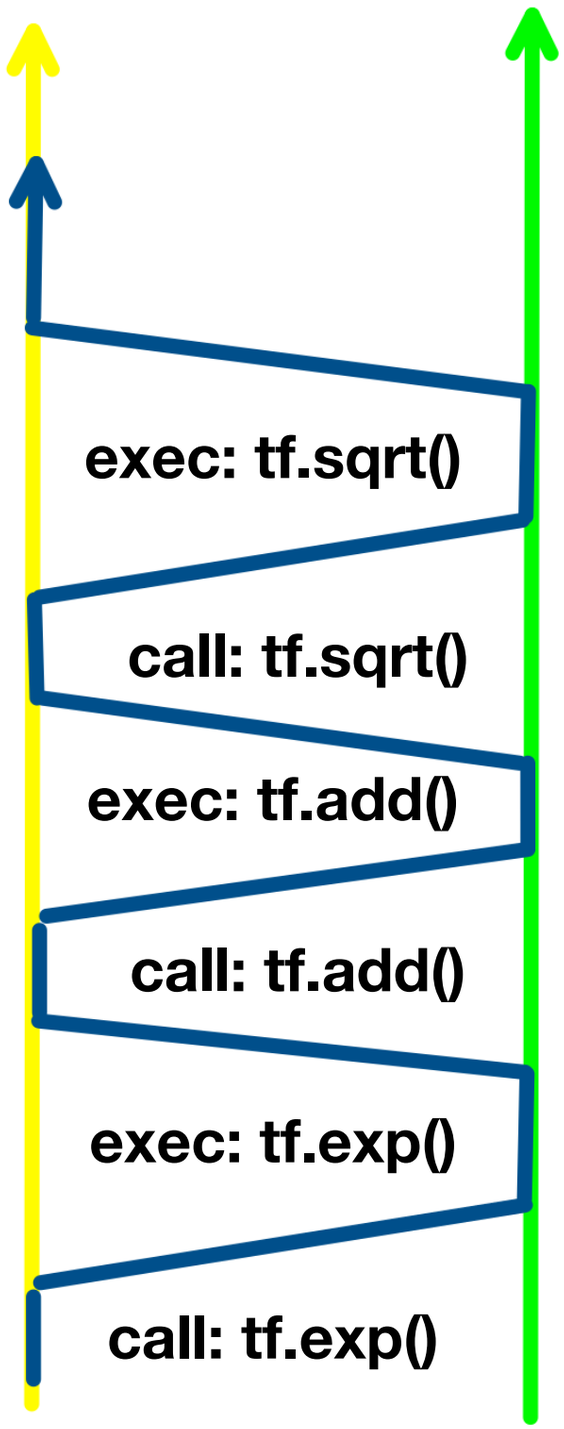

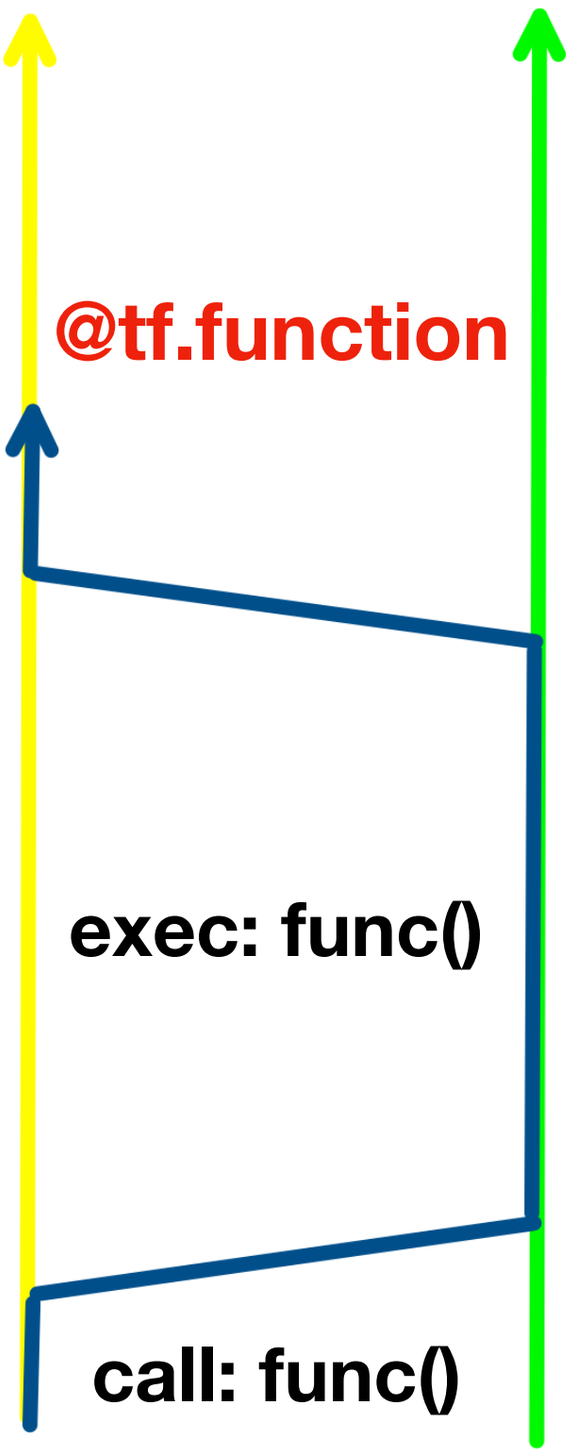

Python Routine

TF Sub-routine

```
@tf.function
def func(inp):
    aa = tf.exp(inp)
    bb = tf.add(aa, 1.)
    cc = tf.sqrt(bb)
    return cc
```

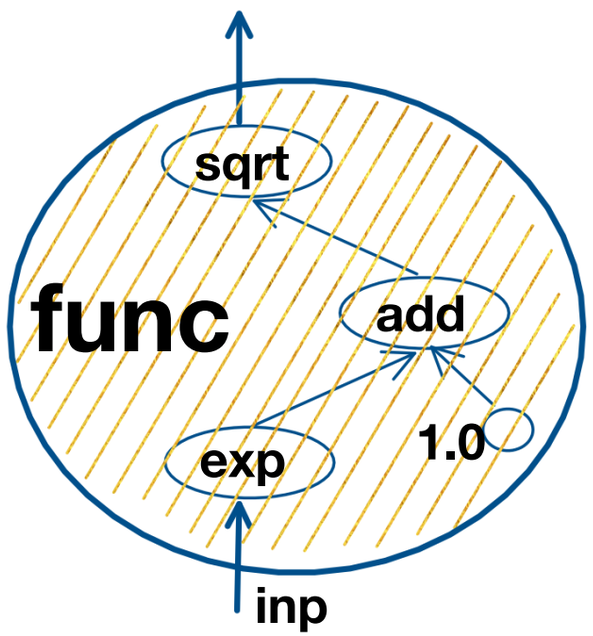

tensorflow2.0 线性回归GD

linear_regression-tf2.0.ipynb